

从任务专用脑电解码器到脑电基座大模型：

EEGNet、EEG Conformer 与 CBraMod 的复现与扩展评测

第一作者 (SUSTech ID)

第二作者 (ID)

第三作者 (ID)

南方科技大学生物医学工程系

BMEB215 机器学习与医学工程应用 · 2026 Spring

1 研究背景 (Background)

1.1 为什么需要脑电基座大模型？

EEG 解码长期面临三个核心困难：

- 标注数据少**——多数 BCI、临床、情绪、睡眠数据集被试数量有限，标签成本高。
- 跨域差异大**——EEG 信号受被试、session、设备、导联、采样率和预处理流程影响明显。
- 评测体系碎片化**——不同论文使用不同 split、滤波、输入尺度，模型之间难以公平比较。

传统任务专用模型 (CNN/RNN/Transformer) 在特定数据集上从零训练，优势是结构明确、参数量小、单任务性能强；劣势是缺少跨任务复用能力，换一个任务往往要重新设计、重新调参。

基座大模型改变的是训练范式：先通过大规模 EEG 数据预训练学习通用表征，再通过 Linear Probing (LP) 或 Fine-Tuning (FT) 适配不同下游任务。

1.2 发展脉络

阶段	代表工作	为什么选它	主要价值
深度学习进入 EEG	EEGNet (2018)	紧凑、领域感知的深度监督模型	高效学习 EEG 特征
全局时序建模	EEG Conformer (2023)	CNN 前端 + Transformer 注意力	长程依赖 + Attention 可视化
大规模预训练	CBraMod (2025)	EEG Foundation Model	预训练 → LP/FT 多任务适配

核心问题：EEGNet 和 EEG Conformer 代表任务专用深度模型，CBraMod 代表从”训练专家模型”到”预训练通用表征再适配下游任务”的范式转变。为什么在专家模型已能在单任务上取得强性能时，我们仍需要脑电基座大模型？

2 模型方法 (Methods)

2.1 EEGNet ——深度学习 EEG 解码代表

用紧凑 CNN 将 EEG 领域知识融入深度学习，是 EEG 解码中最经典的专家模型。

架构：Temporal Convolution (频率时间滤波器) → Depthwise Spatial Convolution (通道空间模式) → Separable Convolution (降参)。每个下游任务单独监督训练。

定位：任务专用深度模型 baseline，与 EEG Conformer、CBraMod 形成”专家模型 vs 基座模型”对照。

2.2 EEG Conformer ——Transformer 增强专家模型

在卷积局部特征提取之后引入 Transformer，用 Self-Attention 建模 Patch 间全局依赖。

架构：CNN 前端提取局部 EEG 特征并形成 Patch Embedding → Transformer Encoder 建模长程时序依赖 → 分类头。Attention Map 可用于可视化分析。

定位：比 EEGNet 更复杂的任务专用 baseline。进行”去掉 Transformer block”消融，检验 Attention 对单任务 EEG 解码的贡献。

2.3 CBraMod ——EEG 基座大模型

通过大规模预训练获得通用 EEG 表征，再迁移到不同下游任务。

下游适配：CBraMod Backbone 输出 Channel-Patch 表征 $B \times C \times S \times D$ 。LP 冻结预训练 Backbone，只训练线性分类头；FT 同时更新 Backbone 和分类头。LP 衡量预训练表征本身是否可读，FT 衡量最终下游适配能力。

2.4 NeuroGate ——神经先验融合

CBraMod 的 Embedding 虽然泛化能力强，但高维隐空间不直接暴露可解释生理量。NeuroGate 用显式 EEG 知识补充 Foundation Embedding。

做法：提取人工神经先验特征 m (时域统计、Band Power、频谱形状、复杂度等)，将 CBraMod 输出的 Backbone Embedding 记为 h ，通过 Gated Fusion 学习门控权重 g ：

$$z = h + g \cdot \phi(m)$$

目的不是让人工特征替代 Foundation Embedding，而是让模型在需要时利用可解释的 EEG 生理知识。

[占位图：模型架构对比] EEGNet / EEG Conformer / CBraMod / NeuroGate 结构示意图。

展示四类模型的关键模块和架构差异。（等待绘制）

3 实验结果 (Results)

3.1 CBraMod 下游任务能否复现？

数据集	版本配置	Seeds	bAcc		κ		论文参考	结论
			Mean	Best	Mean	Best		
BCIC2A	session T/E+CAR	42/2024/3407	0.6382	0.6709	0.5177	0.5612	κ 0.5138	对齐
FACED	baseline official FT	42/2024/3407	0.5245	0.5340	0.4617	0.4718	bAcc 0.5509	接近
ISRUC-S1	baseline official FT	42/2024/3407	0.7780	0.7850	0.7128	0.7373	bAcc 0.7865	基本复现
Physionet-MI	flatten FT	42/2024/3047	0.5975	0.6181	0.4631	0.4903	bAcc 0.6417	接近
SEED-V	baseline official FT	42/2024/3407	0.3927	0.4018	0.2450	0.2592	bAcc 0.4091	接近
SHU-MI	flatten FT	42/2024/3047	0.5851	0.6380	0.1700	0.2756	bAcc 0.6370	best 达到
MDD	flatten FT	42/2024/3047	0.9034	0.9674	0.8008	0.9099	bAcc 0.9560	best 超过
TUEV	baseline official FT	42/2024/3407	0.5499	0.5755	0.5964	0.6343	κ 0.6671	未达

注：bAcc = 平衡准确率， κ = Cohen's Kappa。Mean 为三种子均值，Best 为最优种子。论文参考值口径与对应列一致。

3.2 EEGNet 复现结果

作为任务专用专家模型 Baseline，我们使用原始 EEGNet 在四个运动想象数据集上进行了复现：

数据集	类别数	Val Acc (%)	Test Acc (%)	Test κ
BCICIV2A	4	79.17	–	–
BCICIV2B	2	77.72	78.35	0.5669
IIIa	4	55.95	–	–
Physionet MI (22ch)	4	49.30	–	–

注：BCICIV2A 和 BCICIV2B 为主要结果 (300 epochs)；IIIa 和 Physionet MI 为快速基线 (100 epochs, single seed)，仅作为实现通用性的补充证据。

3.3 复现中的关键经验

CBraMod 输出 $B \times C \times S \times D$ ，其中 C 是通道、 S 是 Patch/Segment、 D 是隐层维度。如果下游 Head 过早对通道求平均 ($B \times C \times S \times D \rightarrow B \times S \times D$)，会丢失 MI 等任务依赖的空间分布信息。

可讲结论：预训练表征不等于下游性能；Foundation Model 还需要与 EEG 结构匹配的 Downstream Readout。

[占位图：Readout 修正前后对比] SHU-MI / Physionet-MI / MDD 数据集上的修正前 vs 修正后

bAcc。

保留 Channel-Patch 结构后部分任务明显恢复。（等待队友数据）

3.4 NeuroGate：神经先验能否增强预训练表征？

可讲结论：NeuroGate 的主证据在 LP，说明显式神经先验能补充 Frozen Foundation Embedding；FT 证据可作为辅助支持。详见表 3.4 和表 3.4。

数据集	CBraMod LP bAcc	NeuroGate LP bAcc	
HMC	0.6149 ± 0.0256	0.6922 ± 0.0172	+0.0773
ISRUC-S1	0.5962 ± 0.0579	0.6934 ± 0.0156	+0.0972
MDD	0.8907 ± 0.0477	0.9062 ± 0.1101	+0.0154
Physionet-MI	0.2719 ± 0.0176	0.2875 ± 0.0083	+0.0156

表 1：冻结骨干网络下的线性探测结果 (LP)。NeuroGate 在睡眠任务 (HMC, ISRUC-S1) 上提升最为显著。

实验设置	结果
LP channel-gated fusion 平均提升 (vs. backbone-only)	+0.0389 BA
LP gated fusion 正提升单元比例 (dataset-backbone)	40/48
CBraMod flatten-FT gated fusion 平均提升	+0.0078 BA (9/12 为正)
FT best-of-gated/logit 平均提升	+0.0097 BA

表 2：Selected-12 数据集上 FT 实验统计结论。

3.5 为什么需要统一 EEG Foundation Benchmark？

目前 EEG Foundation Model 的结果分散在多篇论文中，不同模型、数据集和任务的协议不统一。统一 Benchmark 的必要性：

- 公平比较**——同一数据集、同一 Split、同一预处理、同一指标
- 发现泛化边界**——跨任务 Benchmark 暴露哪些任务仍然困难
- 区分模型能力与协议差异**——减少因数据处理不同导致的伪差距

[占位图：统一 Benchmark 扩展结果] HMC / MDD / Siena_EEG / SleepEDF_full 等数据集

上的 CBraMod 表现。

3-seed avg bAcc + 外部参考值对比。（等待队友数据）

4 总结 (Summary)

4.1 主要结论

- EEGNet 和 EEG Conformer 是任务专用专家模型代表，展示了从紧凑深度模型到 Transformer 增强模型的路线。
- CBraMod 代表另一种范式：大规模预训练 + 下游适配，优势不一定是单任务最高分，而是跨任务复用、少标签迁移和 Benchmark 扩展。
- 专家模型和基座模型应该互补评价，专家模型衡量单任务上限，基座模型衡量通用表征和迁移能力。
- CBraMod 的下游性能依赖合理 Readout，保留 Channel-Patch 结构比过早通道池化更适合 EEG 任务。
- NeuroGate 提供了可解释性补充，通过 Gated Fusion 注入显式 EEG 神经先验，LP 证据最强。
- 统一 Benchmark 是 EEG Foundation Model 发展的必要基础。

EEG Foundation Models 正在解决泛化问题，
而可解释性正在成为新的瓶颈。

NeuroGate 尝试将神经科学知识重新引入 Foundation Models
——其中一个可能的方向。

参考文献

1. Lawhern et al. **EEGNet: A Compact Convolutional Neural Network for EEG-based Brain-Computer Interfaces.** *J. Neural Eng.*, 2018.
2. Song et al. **EEG Conformer: Convolutional Transformer for EEG Decoding and Visualization.** *IEEE TNSRE*, 2023.
3. Wang et al. **CBraMod: A Criss-Cross Brain Foundation Model for EEG Decoding.** *ICLR*, 2025.
4. NeuroGate / NeuroKE 内部参考: neural-prior gated fusion experiments under LP and FT.
5. 本地复现记录: `cbranod_reproduction_results_summary.md`