

从任务专用脑电解码器到脑电基座大模型：EEGNet、EEG Conformer 与 CBraMod 的复现与扩展评测

第一作者 (SUSTech ID) 第二作者 (ID) 第三作者 (ID)

南方科技大学 · 生物医学工程系

1 Introduction

1.1 为什么需要脑电基座大模型？

EEG 解码长期面临三个核心困难：

- 标注数据少**——多数 BCI、临床、情绪、睡眠数据集被试数量有限，标签成本高。
- 跨域差异大**——EEG 信号受被试、session、设备、导联、采样率和预处理流程影响明显。
- 评测体系碎片化**——不同论文使用不同 split、滤波、输入尺度，模型之间难以公平比较。

传统任务专用模型 (CNN/RNN/Transformer) 在特定数据集上从零训练，优势是结构明确、参数量小、单任务性能强；劣势是缺少跨任务复用能力。基座大模型改变的是训练范式：先通过大规模 EEG 数据预训练学习通用表征，再通过 Linear Probing (LP) 或 Fine-Tuning (FT) 适配不同下游任务。

1.2 发展脉络

阶段	代表工作	为什么选它	主要价值
深度学习进入 EEG	EEGNet (2018)	紧凑、领域感知的深度监督模型	高效学习 EEG 特征
全局时序建模	EEG Conformer (2023)	CNN 前端 + Transformer 注意力	长程依赖 + Attention 可视化
大规模预训练	CBraMod (2025)	EEG Foundation Model	预训练 → LP/FT 多任务适配

核心问题：EEGNet 和 EEG Conformer 代表任务专用深度模型，CBraMod 代表从”训练专家模型”到”预训练通用表征再适配下游任务”的范式转变。为什么在专家模型已能在单任务上取得强性能时，我们仍需要脑电基座大模型？

2 Method

2.1 EEGNet ——深度学习 EEG 解码代表

用紧凑 CNN 将 EEG 领域知识融入深度学习，是 EEG 解码中最经典的专家模型。

架构：Temporal Convolution (频率时间滤波器) → Depthwise Spatial Convolution (通道空间模式) → Separable Convolution (降参)。每个下游任务单独监督训练。

定位：任务专用深度模型 baseline，与 EEG Conformer、CBraMod 形成”专家模型 vs 基座模型”对照。

2.2 EEG Conformer ——Transformer 增强专家模型

在卷积局部特征提取之后引入 Transformer，用 Self-Attention 建模 Patch 间全局依赖。

架构：CNN 前端提取局部 EEG 特征并形成 Patch Embedding → Transformer Encoder 建模长程时序依赖 → 分类头。Attention Map 可用于可视化分析。

定位：比 EEGNet 更复杂的任务专用 baseline。进行”去掉 Transformer block”消融，检验 Attention 对单任务 EEG 解码的贡献。

2.3 CBraMod ——EEG 基座大模型

通过大规模预训练获得通用 EEG 表征，再迁移到不同下游任务。

下游适配：CBraMod Backbone 输出 Channel-Patch 表征 $B \times C \times S \times D$ 。LP 冻结预训练 Backbone，只训练线性分类头；FT 同时更新 Backbone 和分类头。LP 衡量预训练表征本身是否可读，FT 衡量最终下游适配能力。

Fig 1. 三类 EEG 解码模型架构对比 (EEGNet / EEG Conformer / CBraMod)。

[占位图：模型架构对比示意图] 横向展示 EEGNet (CNN)、EEG Conformer (CNN+Transformer)、CBraMod (Criss-Cross Attention + Pretraining) 的关键模块和数据流。（等待绘制）

3 Results

3.1 CBraMod 下游任务能否复现？

数据集	版本配置	Seeds	bAcc		κ		论文参考	结论
			Mean	Best	Mean	Best		
BCIC2A	session	42/2024/3407	0.6382	0.6709	0.5177	0.5612	κ 0.5138	对齐
	T/E+CAR							
FACED	baseline official	42/2024/3407	0.5245	0.5340	0.4617	0.4718	bAcc 0.5509	接近
	FT							
ISRUC-S1	baseline official	42/2024/3407	0.7780	0.7850	0.7128	0.7373	bAcc 0.7865	基本复现
	FT							
Physionet-MI	flatten FT	42/2024/3047	0.5975	0.6181	0.4631	0.4903	bAcc 0.6417	接近
SEED-V	baseline official	42/2024/3407	0.3927	0.4018	0.2450	0.2592	bAcc 0.4091	接近
	FT							
SHU-MI	flatten FT	42/2024/3047	0.5851	0.6380	0.1700	0.2756	bAcc 0.6370	best 达到
MDD	flatten FT	42/2024/3047	0.9034	0.9674	0.8008	0.9099	bAcc 0.9560	best 超过
TUEV	baseline official	42/2024/3407	0.5499	0.5755	0.5964	0.6343	κ 0.6671	未达
	FT							

注：bAcc = 平衡准确率， κ = Cohen's Kappa。Mean 为三种子均值，Best 为最优种子。

Fig 2. CBraMod 原文文 8 个下游任务复现全景。多数数据集接近或成功复现论文结果。

3.2 EEGNet 复现结果

数据集	类别数	Val Acc (%)	Test Acc (%)	Test κ
BCICIV2A	4	79.17	—	—
BCICIV2B	2	77.72	78.35	0.5669
IIIIa	4	55.95	—	—
Physionet MI (22ch)	4	49.30	—	—

注：BCICIV2A/BCICIV2B 为主要结果 (300 epochs)；IIIIa/Physionet MI 为快速基线 (100 epochs, single seed)。

3.3 复现中的关键经验

CBraMod 输出 $B \times C \times S \times D$ ，其中 C 是通道、 S 是 Patch/Segment、 D 是隐层维度。如果下游 Head 过早对通道求平均 ($B \times C \times S \times D \rightarrow B \times S \times D$)，会丢失 MI 等任务依赖的空间分布信息。

数据集	修正前 best bAcc	修正后 best bAcc	论文参考
SHU-MI	0.5499	0.6380	0.6370
Physionet-MI	0.5594	0.6181	0.6417
MDD	0.9098	0.9674	0.9560

可讲结论：预训练表征不等于下游性能；Foundation Model 还需要与 EEG 结构匹配的 Downstream Readout。

4 Discussion

4.1 NeuroGate：重新引入神经科学知识

随着模型从 EEGNet 到 CBraMod，表征越来越抽象——从可解释的频段特征 (Alpha/Beta/Theta) 变为高维 Foundation Embedding。NeuroGate 尝试将神经科学先验重新注入 Foundation Model。

核心思路：提取人工神经先验特征 m (时域统计、Band Power、频谱形状等)，通过 Gated Fusion 与 CBraMod 的 Backbone Embedding h 融合：

$$z = h + g \cdot \phi(m)$$

目的不是让人工特征替代 Foundation Embedding，而是让模型在需要时利用可解释的 EEG 生理知识。

4.2 NeuroGate 实验结果

数据集	CBraMod LP bAcc	NeuroGate LP bAcc
HMC	0.6149 ± 0.0256	0.6922 ± 0.0172
ISRUC-S1	0.5962 ± 0.0579	0.6934 ± 0.0156
MDD	0.8907 ± 0.0477	0.9062 ± 0.1101
Physionet-MI	0.2719 ± 0.0176	0.2875 ± 0.0083

表：冻结骨干网络下的线性探测结果 (LP)。睡眠任务提升最为显著。

实验设置	结果
LP channel-gated fusion 平均提升 (vs. backbone-only)	+0.0389 BA
LP gated fusion 正提升单元比例 (dataset-backbone)	40/48
CBraMod flatten-FT gated fusion 平均提升	+0.0078 BA (9/12 为正)
FT best-of-gated/logit 平均提升	+0.0097 BA

表：Selected-12 数据集上 FT 实验统计结论。

Fig 3. NeuroGate LP 实验结果。显式神经先验能补充 Frozen CBraMod Embedding，在睡眠任务 (HMC, ISRUC-S1) 上提升最显著。

4.3 专家模型 vs 基座模型：互补而非替代

模型	核心思路	泛化能力	可解释性
EEGNet	CNN 领域知识	低	高
EEG Conformer	CNN + Transformer	中	中
CBraMod	大规模预训练	高	较低
NeuroGate	+ 神经科学先验	高	预期更高

核心观点：专家模型衡量单任务上限，基座模型衡量通用表征和迁移能力。两者应互补评价，而非简单替代。EEG Foundation Models 正在解决泛化问题，而可解释性正在成为新的瓶颈——NeuroGate 代表其中一个可能的方向。

Fig 4. 四种 EEG 解码模型架构与范式对比。泛化能力持续提升，可解释性成为新挑战。

5 Summary

- EEGNet → EEG Conformer → CBraMod 代表了 EEG 解码从任务专用专家模型走向基座大模型的范式演进。
- CBraMod 在多数原文任务上可复现，但单任务上限不一定超过精心调参的专家模型——其价值在于跨任务复用和统一表征。
- 下游 Readout 设计至关重要：保留 Channel-Patch 结构是发挥 Foundation Model 能力的前提。
- NeuroGate 在 LP 下显著提升 (HMC +0.077, ISRUC-S1 +0.097)，为”可解释性增强基座模型”提供了初步证据。
- 统一 Benchmark 是 EEG Foundation Model 发展的必要基础。

EEG Foundation Models 正在解决泛化问题，而可解释性正在成为新的瓶颈。

NeuroGate 尝试将神经科学知识重新引入 Foundation Models ——其中一个可能的方向。

References

- Lawhern et al. EEGNet: A Compact Convolutional Neural Network for EEG-based Brain-Computer Interfaces. *J. Neural Eng.*, 2018.
- Song et al. EEG Conformer: Convolutional Transformer for EEG Decoding and Visualization. *IEEE TNSRE*, 2023.
- Wang et al. CBraMod: A Criss-Cross Brain Foundation Model for EEG Decoding. *ICLR*, 2025.
- NeuroGate / NeuroKE 内部参考：neural-prior gated fusion experiments under LP and FT.

